

SHAP

Machine Learning Applied

Yomin E. Jaramillo Múnera
EAFIT



Agenda

1. Interpretabilidad
2. Shap



¿Por qué explicabilidad?

- No confiamos plenamente en los modelos
- No sabemos qué pasa en casos extremos
- Los errores pueden ser costosos o nocivos
- ¿Los modelos cometen errores similares a los humanos?
- ¿Cómo corregimos un modelo que no da los resultados esperados?



*La interpretabilidad busca abrir
la “caja negra” del modelo*


**Una forma de abordar estos problemas es la
interpretabilidad**



Problemas: sesgos algorítmicos

- Un estudio de 2018 evaluó la precisión de un sistema comercial de análisis facial en distintos grupos demográficos.
- La precisión cayó notablemente para el grupo de mujeres de piel oscura, evidenciando un sesgo en los datos de entrenamiento.

August 2018 Accuracy on Facial Analysis Pilot Parliaments Benchmark



Amazon Rekognition Performance on Gender Classification

Machine Learning can amplify bias.




- Data set: 67% of people cooking are women
- Algorithm predicts: 84% of people cooking are women



Problemas: ejemplos adversarios

- Pequeñas perturbaciones, imperceptibles para el ojo humano, pueden cambiar por completo la predicción de un modelo.
- Esto revela que el modelo puede apoyarse en patrones distintos a los que usaría una persona.



Misma imagen para el ojo humano; predicción totalmente distinta para el modelo.



Hacia un ML interpretable

Tenemos varios problemas:

- No confiamos en los modelos
- No sabemos qué pasa en casos extremos
- Los errores pueden ser costosos o nocivos
- ¿Los modelos cometen errores similares a los de los humanos?
- ¿Cómo cambiamos el modelo si no da los resultados esperados?

Una forma de lidiar con estos problemas es a través de la interpretabilidad



Definiciones clave: explicabilidad

- **Interpretabilidad:** Grado en que un humano puede entender la causa de una decisión del modelo.
- **Modelo caja negra:** Modelo cuyo funcionamiento interno no es directamente comprensible.
- **Explicación global:** Describe el comportamiento general del modelo en todo el conjunto de datos.
- **Explicación local:** Describe por qué el modelo dio una predicción para una instancia específica.
- **Importancia de característica:** Cuánto aporta cada variable de entrada a una predicción.



SHapley Additive exPlanations – SHAP

- SHAP es un método unificado para interpretar las predicciones de cualquier modelo de Machine Learning.
- Se basa en los valores de Shapley, un concepto de teoría de juegos cooperativos (Lloyd Shapley, 1953).
- Asigna a cada característica una contribución justa a la predicción final.


“A Unified Approach to Interpreting Model Predictions”

Scott M. Lundberg & Su-In Lee — University of Washington (NeurIPS, 2017)



La analogía del juego cooperativo

- Un equipo de jugadores colabora para obtener un premio (payout) en una competencia.
- ¿Cuál es una forma justa de repartir ese premio entre los jugadores según su aporte?




Contribución: cuánto aporta cada jugador al resultado del equipo.



SHAP aplicado a un modelo de ML

- La misma idea se traslada a un modelo: las características (features) son los “jugadores”.
- El “payout” es la predicción del modelo para una instancia dada.

Características de un modelo



El valor de Shapley

$$\phi_i(f, \mathbf{x}) = \sum_{\mathbf{z}' \subseteq \mathbf{x}'} \frac{|\mathbf{z}'|!(M - |\mathbf{z}'| - 1)!}{M!} [f(\mathbf{z}') - f(\mathbf{z}' \setminus i)]$$


- $\mathbf{z}'$: subconjunto de características activas
- $\mathbf{z}' \setminus i$: el mismo subconjunto, sin la característica i
- $f(\mathbf{z}') - f(\mathbf{z}' \setminus i)$: contribución marginal de la característica i en ese subconjunto

$\mathbf{x}'$	Age = 56	Gender = F	BMI = 30	Heart disease = yes	...
$\mathbf{z}'$	Age = 56	Gender = F	BMI = 30	Heart disease = yes	...



¿Cuántas combinaciones hay que evaluar?

- SHAP evalúa, en principio, todos los subconjuntos posibles de características para calcular la contribución marginal de cada una.
- El número total de subconjuntos de un conjunto con n elementos es 2^n .



Con 10 características ($n=10$) existen $2^{10} = 1024$ subconjuntos posibles — por eso SHAP usa aproximaciones eficientes en la práctica.



¡Muchas gracias!

Referencias

- Material de curso: Fundamentos de Aprendizaje Automático, Universidad EAFIT.

